

Classificação de domínios de intensidade de exercício em imagens termográficas de ratos sob avaliação em nível de sujeito

Pedro Bernini^{1*}, Guilherme Henrique Rodrigues¹,
Fúlvia Barros Manchado Gobatto², Claudio Alexandre Gobatto²,
André Franceschi Angelis¹, Ulisses Dias¹

^{1*}Faculdade de Tecnologia, Universidade Estadual de Campinas,
Limeira, São Paulo, Brasil.

²Faculdade de Ciências Aplicadas, Universidade Estadual de Campinas,
Limeira, São Paulo, Brasil.

*Corresponding author(s). E-mail(s): p204575@dac.unicamp.br;
Contributing authors: g290200@dac.unicamp.br; fgobatto@unicamp.br;
cgobatto@unicamp.br; andre@ft.unicamp.br; ulissesd@unicamp.br;

Abstract

O exercício físico atua como estressor fisiológico, induzindo alterações agudas nas respostas corporais em relação ao repouso. A classificação precisa da intensidade de exercício é essencial para otimizar estratégias de treinamento voltadas à saúde ou ao desempenho. Os métodos convencionais de determinação dos domínios de intensidade são frequentemente invasivos ou dependem de equipamento caro. Nesse contexto, a imagem térmica oferece abordagem não invasiva promissora. Modelos de roedores são amplamente empregados em fisiologia do exercício para investigar novas metodologias de avaliação física e fisiológica. Neste estudo, avaliamos modelos de aprendizado profundo para a classificação de domínios distintos de intensidade de exercício em ratos a partir de imagens termográficas, sob um protocolo de avaliação em nível de sujeito. O banco foi construído a partir de vídeos de roedores correndo em intensidades determinadas individualmente — aquecimento, moderada, intensa e severa. Como frames consecutivos de vídeo são quase-duplicatas e o rótulo é colinear ao tempo decorrido de sessão, todos os frames de um mesmo animal são atribuídos a um único conjunto, e os quatro animais que percorreram os quatro domínios rotacionam como teste e validação. Duas famílias de modelos — uma rede convolucional treinada do zero e um extrator ResNet50 acoplado a um classificador Random Forest —

são comparadas sobre partições idênticas, em quatro granularidades de rotulação. A distribuição espacial das atribuições SHAP é quantificada por razão de densidade entre a região do animal e o fundo. O extrator pré-treinado supera a rede treinada do zero em 15 das 16 comparações pareadas por fold. Na decisão binária entre domínios subliminares e supraliminares, alcança F_1 macro de 0,881, contra 0,378 da predição da classe majoritária; no problema completo de quatro classes, 0,460 contra 0,117, com a classe severa não recuperada em metade dos folds. O ganho obtido ao agrupar classes é fortemente assimétrico: sob partição idêntica e mesma redução no número de classes, fundir a fronteira da máxima fase estável de lactato rende mais que o dobro do ganho de fundir a fronteira do limiar aeróbio, o que localiza a informação ausente em uma única fronteira. As atribuições são espacialmente concentradas sobre regiões quentes do quadro — enriquecimento de 2,92 para o extrator pré-treinado e 2,01 para a rede treinada do zero —, mas a máscara empregada não separa o animal das superfícies aquecidas do equipamento, de modo que o confundimento ambiental permanece parcialmente em aberto. Os resultados sustentam a viabilidade da termografia para discriminação grosseira de intensidade em animais não vistos e delimitam, ao mesmo tempo, o que o banco disponível não permite estabelecer: a fronteira fisiologicamente decisiva não é recuperável com quatro animais representando o domínio severo. Ampliar a coorte é a única via para elevar o poder do desenho.

Keywords: termografia, domínios de intensidade de exercício, ratos Wistar, redes neurais convolucionais, aprendizado profundo, vazamento de dados, validação em nível de sujeito

1 Introdução

A prescrição individualizada e precisa da intensidade de exercício é determinante para que um programa de treinamento alcance seus objetivos, seja a melhora da qualidade de vida relacionada à saúde, seja o aprimoramento do desempenho atlético. Entre as variáveis que definem a carga de treinamento, a intensidade merece atenção particular por influenciar diretamente a magnitude e a especificidade das adaptações morfofuncionais induzidas pelo treinamento sistemático [Goncalves et al. \(2021\)](#).

Nesse contexto, a classificação em domínios distintos de intensidade — baixo (aquecimento), moderado, intenso e severo — pode ser identificada individualmente a partir das respostas fisiológicas agudas [Gaesser and Poole \(1996\)](#); [Goncalves et al. \(2021\)](#). Esses domínios refletem a interação complexa entre vias metabólicas, transporte de oxigênio e demanda muscular. No domínio moderado, as respostas cardiorrespiratórias e metabólicas atingem estado estável em valores relativamente baixos, indicando que a demanda energética é adequadamente suprida pelo metabolismo oxidativo. Em contraste, o domínio severo caracteriza-se pela impossibilidade de alcançar estado estável fisiológico: as respostas metabólicas, ventilatórias e cardiovasculares crescem continuamente e o esforço termina inevitavelmente próximo ao máximo [Poole and Richardson \(1997\)](#). O domínio intenso ocupa posição intermediária, na qual as respostas fisiológicas inicialmente se elevam mas acabam por estabilizar em patamares superiores aos do domínio moderado [Beneke \(2003\)](#). A fronteira superior que separa o domínio intenso

do severo pode ser determinada pela máxima fase estável de lactato (MFEL) [Beneke \(2003\)](#); [Billat et al. \(2003\)](#).

A despeito da importância bem documentada de identificar corretamente esses domínios, tanto para a ciência do esporte aplicada quanto para a prescrição clínica de exercício, sua avaliação é frequentemente negligenciada na prática. Essa lacuna pode ser atribuída a alguns fatores limitantes. Em primeiro lugar, os métodos mais consolidados envolvem procedimentos invasivos, como coletas repetidas de sangue para determinação da lactacidemia [Billat et al. \(2003\)](#); [Faude et al. \(2009\)](#), nem sempre viáveis em rotina ou em larga escala. Em segundo lugar, técnicas avançadas — como a medida direta do consumo pulmonar de oxigênio ou a dinâmica de oxigenação muscular por espectroscopia no infravermelho próximo [Iannetta et al. \(2017\)](#); [Perrey et al. \(2024\)](#) — exigem equipamento caro e sofisticado, de acesso restrito. Em conjunto, essas barreiras dificultam a incorporação sistemática da avaliação por domínios às rotinas de treinamento, apesar de seu reconhecido potencial para otimizar a prescrição de exercício [Jamnick et al. \(2020\)](#).

O uso da termografia desponta como opção viável no esporte, dada sua eficácia no auxílio ao diagnóstico de lesões musculares e o baixo custo da varredura corporal do atleta [Gomez-Carmona et al. \(2020\)](#); [Hildebrandt et al. \(2010\)](#). A técnica é simples, fornece informação em tempo real e é não invasiva, características que a tornam atraente para monitoramento durante o esforço [Masur et al. \(2024\)](#); [Da Silva et al. \(2024\)](#).

Redes neurais convolucionais permitem que modelos computacionais aprendam representações de imagens em múltiplos níveis de abstração [LeCun et al. \(2015\)](#) e, portanto, apresentam-se como abordagem promissora para o processamento automático de imagens termográficas [Cañada-Soriano et al. \(2023\)](#); [He et al. \(2021\)](#). É importante enfatizar, contudo, que o estado da arte para o uso de modelos de aprendizado profundo em conjunto com termografia na identificação de domínios de intensidade de exercício ainda não está estabelecido. Embora existam estudos que exploram a termografia como ferramenta auxiliar na medicina esportiva, ainda são necessárias evidências empíricas suficientes para verificar a acurácia dos dados obtidos por imagens termográficas durante o treinamento de atletas ou de animais para a determinação de domínios de intensidade.

Nesse contexto, o uso de modelos animais como ratos e camundongos apresenta-se como alternativa viável e amplamente aceita na pesquisa científica para o estudo das respostas fisiológicas ao exercício [Gobatto et al. \(2001\)](#). Desde que empregados corretamente no contexto do exercício [Booth et al. \(2010\)](#), os roedores são ferramentas relevantes em estudos de fisiologia experimental pela facilidade de manejo, pela reprodutibilidade dos protocolos e por similaridades fisiológicas pertinentes com seres humanos em aspectos metabólicos e cardiovasculares [Kemi and Wisløff \(2010\)](#); [Orsi et al. \(2023\)](#). Além disso, o uso de animais permite maior controle sobre variáveis ambientais e sobre a intensidade dos estímulos, o que facilita a obtenção de dados precisos e padronizados para a validação de novas abordagens. Estudos prévios já demonstraram o potencial da termografia em modelos animais para investigar alterações fisiológicas complexas, como as associadas à dor neuropática [Bennett and Ochoa \(1991\)](#) e à temperatura corporal após treinamento em altitude [Scariot et al. \(2023\)](#), reforçando

que as respostas térmicas observadas em roedores podem refletir padrões similares aos humanos.

O problema da unidade de avaliação

Há, entretanto, uma dificuldade metodológica específica que precede qualquer discussão sobre desempenho, e que é característica deste tipo de dado. Bancos de imagens termográficas derivados de vídeo são construídos por extração de frames, e os rótulos de intensidade são atribuídos por janela temporal dentro de cada sessão. Disso decorrem duas consequências. Primeira, frames consecutivos são quase-duplicatas: o número efetivo de observações independentes aproxima-se do número de sessões, não do número de imagens. Segunda, o rótulo é colinear ao tempo decorrido de sessão, de modo que qualquer pista ambiental com deriva temporal — aquecimento da superfície do equipamento, condensação, deriva do sensor — fica disponível ao classificador como atalho.

Sob essas condições, o modo como o banco é particionado determina o que a métrica reportada de fato mede. Uma partição sorteada sobre frames individuais coloca quase-duplicatas de cada imagem de teste no conjunto de treinamento, e o escore resultante mede reconhecimento de material já visto, não generalização [Kaufman et al. \(2012\)](#); [Saeb et al. \(2017\)](#). Esse é um modo de falha recorrente e quantitativamente severo: em imagens médicas, o particionamento na unidade errada elevou artificialmente a acurácia de teste em até 55 % e, sob rótulos aleatórios, produziu cerca de 96 % de acurácia onde a partição por sujeito produziu os 50 % do acaso [Yagis et al. \(2021\)](#). Levantamentos sistemáticos identificaram o problema em centenas de publicações ao longo de dezessete disciplinas [Kapoor and Narayanan \(2023\)](#), e ele figura entre as falhas metodológicas centrais em aprendizado de máquina aplicado a imagens médicas [Varoquaux and Cheplygina \(2022\)](#). Em um domínio no qual o estado da arte ainda não está estabelecido, estimativas otimistas por construção não apenas superestimam o desempenho: elas orientam a agenda de pesquisa na direção errada.

Objetivo e contribuições

O objetivo deste estudo é avaliar a aplicação de modelos de aprendizado profundo à classificação de domínios de intensidade de exercício a partir de alterações fisiológicas registradas por imagens termográficas de ratos durante esforço em esteira, sob um protocolo de avaliação construído para que as estimativas correspondam ao cenário de uso pretendido: a aplicação a um animal não visto.

As contribuições são as seguintes.

1. **Um protocolo de avaliação em nível de sujeito.** Todos os frames de um mesmo animal são atribuídos a um único conjunto, e os quatro animais que percorreram os quatro domínios rotacionam como teste e validação, produzindo quatro estimativas independentes em vez de um valor pontual. Os intervalos de confiança são obtidos por reamostragem por sujeito, refletindo a base efetiva da estimativa.
2. **Comparação entre duas famílias de modelos sob partições idênticas.** Uma rede convolucional treinada do zero e um extrator ResNet50 pré-treinado acoplado

a um classificador Random Forest são avaliados sobre exatamente os mesmos folds, de modo que a diferença observada seja atribuível ao modelo e não à partição.

3. **Quatro granularidades de rotulação sobre a mesma partição.** Do problema completo de quatro classes à decisão binária sub-*versus* supra-MFEL, permitindo isolar o efeito da granularidade sobre o desempenho.
4. **Uma verificação explícita do confundimento ambiental.** Atribuições SHAP [Lundberg and Lee \(2017\)](#) são quantificadas por meio de uma razão de densidade entre a região do animal e o fundo, o que responde diretamente se o modelo extrai evidência do animal ou do equipamento — questão que métricas de desempenho, isoladamente, não resolvem.

Os resultados indicam que o extrator pré-treinado supera a rede treinada do zero em quinze das dezesseis comparações pareadas por fold; que o desempenho é adequado à decisão binária entre domínios subliminares e supraliminares (F_1 macro de 0,881 contra 0,378 da predição da classe majoritária) e insuficiente na separação de quatro classes (0,460 contra 0,117, com a classe Severo não recuperada em metade dos folds); e que o ganho obtido ao agrupar classes é assimétrico de modo informativo — fundir a fronteira da MFEL rende mais que o dobro do ganho de fundir a fronteira do limiar aeróbio, sob partição idêntica e mesma redução no número de classes. A análise de atribuição mostra concentração espacial sobre regiões quentes do quadro, sem porém permitir separar o animal das superfícies aquecidas do equipamento. Cabe antecipar que os valores aqui reportados são substancialmente inferiores aos que se obteriam sob partição no nível de frame; essa diferença não indica modelos piores, e sim uma pergunta diferente e mais exigente sendo respondida.

Trabalhos relacionados

A pesquisa em fisiologia do exercício voltada à classificação de domínios de intensidade por aprendizado de máquina e termografia é ainda escassa. Não obstante a ausência de trabalhos diretamente relacionados, estudos em áreas próximas fornecem a fundamentação deste estudo. Organizamos o levantamento em três frentes: a termografia como instrumento de medida em medicina esportiva, o uso de aprendizado profundo sobre imagens térmicas, e a determinação dos domínios de intensidade propriamente ditos.

Termografia em medicina esportiva.

Nos últimos anos, a termografia consolidou-se como ferramenta confiável para a análise de alterações fisiológicas relacionadas à temperatura da pele, com potencial relevante no tratamento de lesões em atletas humanos [Hildebrandt et al. \(2010\)](#). A técnica auxilia na detecção de processos inflamatórios, sobretudo pouco após o treinamento, permitindo avaliar a presença e a extensão de lesões musculares [Verderber et al. \(2024\)](#). Revisões sistemáticas com metanálise avaliaram sua acurácia no diagnóstico de lesões musculoesqueléticas [Sanchis-Sánchez et al. \(2014\)](#) e de tendinopatias [Lacerda et al. \(2022\)](#), e a técnica mostrou-se útil no diagnóstico de condições neuromusculares dolorosas, como a síndrome do túnel do carpo [Bargiel et al. \(2021\)](#). Convém registrar que esses trabalhos posicionam a termografia como ferramenta complementar ao exame clínico, e não como substituta.

Em ambientes com temperatura controlada e equipamento especializado, a termografia foi avaliada para detecção de dano muscular após o treinamento [Verderber et al. \(2024\)](#); [Da Silva et al. \(2024\)](#), com foco na presença e extensão da lesão mais do que em sua localização precisa. Estudos recentes examinaram também a resposta de parâmetros termográficos a exercício específico e não específico, e sua relação com parâmetros de carga interna [Masur et al. \(2024\)](#), e a resposta da temperatura da pele a diferentes volumes de exercício ao longo das 24 horas subsequentes [Da Silva et al. \(2024\)](#). Em conjunto, esses trabalhos estabelecem que o sinal térmico responde ao esforço; nenhum deles, porém, aborda a classificação em domínios de intensidade.

Aprendizado profundo sobre imagens térmicas.

O uso de redes convolucionais sobre imagens termográficas pode contribuir de forma significativa para a detecção e classificação de objetos com alta precisão e eficiência, com potencial de automatizar a análise termográfica [He et al. \(2021\)](#). Em aplicação clínica direta, algoritmos de aprendizado de máquina foram empregados sobre imagens térmicas para a classificação automática de bloqueios simpáticos lombares [Cañada-Soriano et al. \(2023\)](#), demonstrando que representações aprendidas capturam padrões térmicos sutis não perceptíveis visualmente. Essa literatura fundamenta a viabilidade técnica da abordagem, mas foi desenvolvida sobre imagens estáticas de sujeitos distintos, e não sobre sequências de vídeo de um mesmo indivíduo — distinção que, como argumentado acima, é decisiva para o desenho da avaliação.

Determinação dos domínios de intensidade.

Os métodos correntes de determinação da intensidade de exercício foram objeto de exame e crítica sistemáticos [Jamnick et al. \(2020\)](#), que apontam inconsistências na definição e na operacionalização das fronteiras entre domínios. Em modelos de roedores, a MFEL foi caracterizada em protocolos de natação [Gobatto et al. \(2001\)](#) e mostrou-se dependente do ergômetro empregado [Manchado et al. \(2006\)](#); trabalhos mais recentes relacionaram velocidade crítica, MFEL e marcadores musculares após corrida exaustiva em camundongos [Orsi et al. \(2023\)](#). Essa literatura é o que sustenta a validade dos rótulos empregados neste estudo: os domínios não são divisões arbitrárias do esforço, mas transições metabólicas determinadas individualmente por método invasivo de referência.

A intersecção das três frentes — termografia, aprendizado profundo e domínios de intensidade — permanece, até onde levantamos, inexplorada. É essa lacuna que o presente estudo aborda.

2 Resultados

Todos os números desta seção foram obtidos sob o protocolo descrito na Seção 5.3: partição em nível de sujeito, quatro folds rotativos sobre os quatro animais que percorreram os quatro domínios, e uma única avaliação de teste por fold, realizada após a seleção de modelo ter sido concluída exclusivamente sobre o sujeito de validação. Os quatro cenários de rotulação (Tabela 7) compartilham exatamente a mesma partição, de modo que as diferenças entre eles são atribuíveis apenas ao mapa de rótulos.

A métrica primária é o F_1 macro; a acurácia é reportada apenas como referência secundária, pelas razões dadas na Seção 5.6.

Cada valor é acompanhado da referência que lhe dá escala. Para o F_1 macro, a referência é o classificador que prevê sempre a classe majoritária do conjunto de teste; para a acurácia balanceada, é o piso do acaso, $1/k$. Sem essas referências os cenários não são comparáveis entre si, porque o número de classes muda de quatro a dois e as duas linhas de base variam com ele.

2.1 Treinamento

A parada antecipada foi acionada em todos os 32 treinamentos (quatro folds, quatro cenários, duas famílias); o limite de 200 épocas nunca foi atingido. A rede convolucional treinada do zero convergiu entre a 1ª e a 94ª época, com mediana entre a 10ª e a 11ª; o extrator pré-treinado, entre a 1ª e a 20ª, com mediana na 8ª. A convergência mais rápida do segundo é esperada: apenas o último estágio residual e a camada de saída são ajustados, sobre representações já formadas.

A distância entre o escore de validação e o escore de teste é substancialmente maior para a rede treinada do zero. Tomando a média dos quatro folds em cada cenário, a queda do F_1 macro de validação para teste foi de 0,152 a 0,229 para a rede convolucional e de 0,038 a 0,095 para o extrator pré-treinado. Como validação e teste são animais distintos em ambos os casos, essa diferença mede transferência entre indivíduos, e não sobreajuste ao conjunto de validação. Ela indica que a rede treinada do zero, com onze animais disponíveis e nove efetivamente em treinamento, ajusta-se à idiossincrasia dos animais vistos.

O colapso na classe majoritária, definido na Seção 5.6 como a concentração de ao menos 80 % das predições em uma única classe, ocorreu em 11 dos 32 treinamentos. Ele é reportado por fold na Tabela 1. A rede convolucional colapsou em seis folds, distribuídos pelos quatro cenários; o extrator pré-treinado, em cinco, todos concentrados em TRÊS-A e BINÁRIO. O extrator pré-treinado não colapsou em nenhum fold dos cenários QUATRO e TRÊS-B.

Table 1 Folds em que o modelo concentrou ao menos 80 % das predições de teste em uma única classe. Entre parênteses, a fração efetivamente concentrada.

Cenário	Rede convolucional	ResNet50 + RF
QUATRO	10 (85 %), 11 (90 %)	—
TRÊS-A	9 (90 %), 10 (99 %)	1 (82 %), 9 (85 %), 11 (83 %)
TRÊS-B	1 (100 %)	—
BINÁRIO	1 (88 %)	1 (84 %), 9 (80 %)

Identificadores referem-se ao animal que compôs o conjunto de teste do fold.

2.2 Desempenho por cenário

A Tabela 2 apresenta o desempenho das três configurações avaliadas em cada cenário. Além das duas famílias descritas na Seção 5.4, reportamos separadamente a cabeça linear treinada no primeiro estágio do modelo pré-treinado. Ela não é um modelo adicional: é o classificador que já existe ao final do ajuste supervisionado da ResNet50, e sobre cujas representações o Random Forest é posteriormente ajustado. Como compartilha o mesmo backbone, os mesmos folds e o mesmo conjunto de teste, ela é a referência direta contra a qual o ganho do Random Forest deve ser medido. Reportá-la é o que permite distinguir o efeito da representação aprendida do efeito do classificador acoplado a ela.

Table 2 Desempenho no conjunto de teste por cenário e configuração. Média dos quatro folds; entre colchetes, intervalo de 95 % obtido por reamostragem *bootstrap* percentil das quatro estimativas em nível de sujeito. As linhas de referência trazem o F_1 macro da predição da classe majoritária e o piso do acaso da acurácia balanceada.

Cenário	Configuração	F_1 macro	IC 95 %	Ac. bal.	Acurácia
QUATRO	Rede convolucional	0,254	[0,210, 0,325]	0,336	0,365
	ResNet50 + RF	0,460	[0,322, 0,598]	0,561	0,577
	ResNet50 + linear	0,443	[0,277, 0,608]	0,550	0,544
	<i>referência</i>	0,117	—	0,250	—
TRÊS-A	Rede convolucional	0,339	[0,248, 0,429]	0,377	0,600
	ResNet50 + RF	0,472	[0,463, 0,484]	0,521	0,726
	ResNet50 + linear	0,475	[0,407, 0,542]	0,546	0,687
	<i>referência</i>	0,252	—	0,333	—
TRÊS-B	Rede convolucional	0,309	[0,155, 0,463]	0,374	0,361
	ResNet50 + RF	0,663	[0,591, 0,734]	0,680	0,669
	ResNet50 + linear	0,693	[0,629, 0,737]	0,709	0,713
	<i>referência</i>	0,187	—	0,333	—
BINÁRIO	Rede convolucional	0,553	[0,422, 0,754]	0,565	0,617
	ResNet50 + RF	0,784	[0,730, 0,848]	0,772	0,819
	ResNet50 + linear	0,881	[0,842, 0,921]	0,875	0,893
	<i>referência</i>	0,378	—	0,500	—

Três leituras decorrem diretamente da tabela.

O extrator pré-treinado supera a rede treinada do zero em todos os cenários.

A vantagem em F_1 macro vai de 0,133 (TRÊS-A) a 0,354 (TRÊS-B), e a direção é consistente em 15 das 16 comparações pareadas por fold. A única exceção ocorre no cenário BINÁRIO, fold do animal 9, em que a rede convolucional atinge 0,860 contra 0,769 do Random Forest. Pelas razões dadas na Seção 5.6, não acompanhamos essa comparação de um p -valor; o que sustenta a conclusão é a consistência da direção

somada à magnitude das diferenças, não um teste de hipótese que o número de folds não permite.

O ganho ao agrupar classes não é uniforme, e essa assimetria é o resultado central.

Os dois cenários de três classes partem do mesmo problema de quatro classes, usam a mesma partição e a mesma arquitetura, e diferem apenas em qual par de domínios é fundido. O ganho sobre a respectiva referência, tomando a melhor configuração de cada cenário, é de 0,223 em TRÊS-A, que funde os dois domínios sublimiáres, e de 0,506 em TRÊS-B, que funde os dois supralimiáres. Se o ganho decorresse apenas da redução do número de classes, os dois valores seriam próximos. Não são: fundir a fronteira da MFEL vale mais que o dobro de fundir a fronteira do limiar aeróbio. O cenário BINÁRIO, que também funde a MFEL, alcança ganho de 0,503, praticamente idêntico ao de TRÊS-B apesar de ter uma classe a menos.

O Random Forest não se distingue da cabeça linear sobre a qual é ajustado.

Em 16 comparações pareadas por fold, o Random Forest supera a cabeça linear em sete. Nos cenários QUATRO, TRÊS-A e TRÊS-B a diferença média entre os dois fica em 0,018, $-0,003$ e $-0,030$, respectivamente — dentro da dispersão entre folds em todos os casos. No cenário BINÁRIO a diferença é maior e favorece a cabeça linear: 0,881 contra 0,784, com vantagem em três dos quatro folds, chegando a 0,157 no fold do animal 10.

2.3 Desempenho por classe

O F_1 macro agregado não distingue um modelo que erra de forma difusa de um que ignora integralmente uma classe. A Tabela 3 traz a revocação por classe, com destaque para os domínios Intenso e Severo, cuja detecção é a de maior consequência prática.

Table 3 Revocação por classe no conjunto de teste, média dos quatro folds. Colchetes indicam classes fundidas no cenário.

Cenário	Configuração	Baixo	Moderado	Intenso	Severo
QUATRO	Rede convolucional	0,502	0,309	0,343	0,189
	ResNet50 + RF	0,864	0,555	0,411	0,415
	ResNet50 + linear	0,816	0,487	0,382	0,517
TRÊS-A	Rede convolucional		0,848	0,277	0,005
	ResNet50 + RF		0,990	0,379	0,195
	ResNet50 + linear		0,893	0,406	0,339
TRÊS-B	Rede convolucional	0,460	0,404	0,259	
	ResNet50 + RF	0,763	0,730	0,546	
	ResNet50 + linear	0,706	0,711	0,711	
BINÁRIO	Rede convolucional		0,811	0,319	
	ResNet50 + RF		0,991	0,552	
	ResNet50 + linear		0,943	0,806	

No cenário QUATRO, a revocação média de Severo é de 0,415 para o Random Forest, mas essa média agrega comportamentos qualitativamente distintos. Nos folds dos animais 9 e 10 a revocação é exatamente zero: a coluna de predições da classe Severo na matriz de confusão está inteiramente vazia, e o modelo nunca emite esse rótulo. No fold do animal 10 isso significa que, dos 723 frames de Severo desse animal — a maior quantidade dessa classe em um único sujeito do banco —, 710 foram classificados como Intenso e os 13 restantes como Moderado. Nos folds dos animais 1 e 11 ocorre o oposto: a revocação de Severo alcança 0,905 e 0,755, mas às custas de Intenso, cuja revocação cai a 0,030 e 0,090. No fold do animal 1, 846 dos 1.390 frames de Intenso são classificados como Severo.

O par Intenso–Severo comporta-se, portanto, como uma única classe cuja fronteira interna o modelo não localiza, e a direção do erro depende de quais animais compõem o treinamento daquele fold. No cenário TRÊS-A, que mantém os dois separados, a revocação média de Severo cai a 0,005 para a rede convolucional e a 0,195 para o Random Forest, com zero exato em dois dos quatro folds em ambas as famílias.

2.4 Estrutura dos erros

Os quatro rótulos estão ordenados ao longo de um contínuo fisiológico. A Tabela 4 traz a proporção das classificações incorretas que recaem sobre uma classe adjacente na ordem Baixo–Moderado–Intenso–Severo.

Table 4 Proporção dos erros de teste que recaem sobre classe adjacente, média dos quatro folds. No cenário BINÁRIO a adjacência é 1,000 por construção e é omitida.

Cenário	Rede convolucional	ResNet50 + RF
QUATRO	0,626	0,880
TRÊS-A	0,788	0,895
TRÊS-B	0,587	0,894

Para o extrator pré-treinado, entre 88% e 90% dos erros são de um único estágio de distância, com pouca variação entre cenários. A rede convolucional apresenta adjacência mais baixa e mais variável (0,587 a 0,788), o que é consistente com os episódios de colapso registrados na Tabela 1: um modelo que concentra predições em uma classe produz erros de duas e três posições de distância.

Alta adjacência é compatível com duas hipóteses distintas, e a distinção entre elas é retomada na Seção 2.5: ou os domínios vizinhos são termicamente semelhantes, e o erro reflete uma fronteira genuinamente difusa, ou o modelo rastreia o tempo decorrido de sessão, que é monotônico na ordem dos rótulos, e o erro reflete imprecisão nessa contagem.

2.5 Atribuição espacial

O enriquecimento de atribuição E (Equação 1) foi calculado sobre 181 frames de teste, distribuídos entre os quatro cenários, os quatro folds e as duas famílias, correspondendo a um acerto e um erro por classe em cada combinação. A máscara do animal ocupa, em média, 10,3 % do quadro.

Table 5 Enriquecimento de atribuição E por cenário e família, média dos frames explicados. $E = 1$ corresponde a atribuição indistinguível da uniforme.

Cenário	Rede convolucional	ResNet50
QUATRO	1,81	2,89
TRÊS-A	2,27	2,86
TRÊS-B	1,79	2,96
BINÁRIO	2,37	3,00
Todos	2,01	2,92

Para a família ResNet50 + RF, a atribuição é computada sobre a rede com a cabeça linear, uma vez que o Random Forest não é diferenciável e não admite atribuição em nível de pixel.

Em 174 dos 181 frames o enriquecimento excede 1,3; nenhum frame ficou abaixo de 0,8. A verificação por caminho independente é consistente: se a atribuição fosse uniforme, a fração que recai fora da máscara seria de aproximadamente 89,7 %, dada a área do animal; a fração observada é de 76,5 % para o extrator pré-treinado e 81,2 % para a rede convolucional. Há, portanto, concentração mensurável sobre a região térmica correspondente ao animal, e ela é maior no extrator pré-treinado.

Dois padrões adicionais merecem registro. Primeiro, o enriquecimento é praticamente idêntico entre frames corretamente e incorretamente classificados: 2,029 contra 2,000 para a rede convolucional e 2,940 contra 2,904 para o extrator pré-treinado. A localização espacial da atribuição não distingue acerto de erro. Segundo, o enriquecimento é estável entre cenários — 2,86 a 3,00 para o extrator pré-treinado — enquanto o F_1 macro do mesmo modelo varia de 0,460 a 0,784 entre esses cenários. Redes treinadas separadamente em cada cenário convergem para o mesmo padrão espacial de atenção, com desempenhos muito distintos.

A interpretação desses valores está sujeita a uma limitação de método que delimita o que eles permitem concluir, e que é tratada na Seção 3.3.

3 Discussão

3.1 A escala contra a qual estes números devem ser lidos

A comparação natural para os valores da Tabela 2 não é a literatura de classificação sobre imagens térmicas, e sim o piso do acaso do cenário correspondente. A razão é a

discutida na Seção 5.3: escores obtidos sob partição no nível de frame e escores obtidos sob partição no nível de sujeito respondem a perguntas diferentes. O primeiro mede reconhecimento de material já visto; o segundo, generalização para um indivíduo novo [Saeb et al. \(2017\)](#); [Little et al. \(2017\)](#). Colocá-los lado a lado numa mesma tabela sugeriria uma degradação de desempenho onde há, na verdade, uma troca de pergunta.

Lidos contra a referência apropriada, os resultados sustentam uma conclusão limitada e uma negativa. O extrator pré-treinado supera a predição da classe majoritária por 0,343 de F_1 macro no cenário de quatro classes e por 0,503 no binário, e supera o piso do acaso da acurácia balanceada em todos os cenários. Há, portanto, sinal térmico associado à intensidade de exercício que sobrevive à troca de indivíduo. Simultaneamente, nenhum cenário alcança desempenho compatível com uso aplicado: mesmo o melhor resultado, 0,881 de F_1 macro no cenário binário, corresponde a uma revocação de 0,806 na classe supraliminar, ou seja, aproximadamente um em cada cinco frames de alta intensidade não detectado.

3.2 Adjacência dos erros e o que ela não decide sozinha

Entre 88% e 90% dos erros do extrator pré-treinado recaem sobre uma classe adjacente. Isoladamente, esse valor admite duas explicações incompatíveis.

A primeira é que domínios vizinhos são termicamente semelhantes. As transições entre domínios são metabólicas, não térmicas [Beneke \(2003\)](#); [Jamnick et al. \(2020\)](#): a MFEL demarca o ponto em que o lactato deixa de estabilizar, e nada garante que esse ponto corresponda a uma descontinuidade na temperatura de superfície. Sob essa leitura, a alta adjacência é a assinatura de um sinal genuíno medido com resolução insuficiente para separar estágios contíguos.

A segunda é que o modelo rastreia o tempo decorrido de sessão. Como os rótulos são definidos por janelas temporais consecutivas (Seção 5.1), qualquer pista com deriva monotônica ao longo da gravação — aquecimento da esteira, condensação, deriva do sensor — produziria exatamente o mesmo padrão: erros concentrados em estágios vizinhos, porque a contagem de tempo estaria aproximadamente correta. Sob essa leitura, a alta adjacência não indica sinal fisiológico algum.

Métricas de desempenho não separam essas hipóteses, e é por isso que a análise de atribuição da Seção 5.7 foi incluída no desenho, e não acrescentada como ilustração.

3.3 Atribuição ao animal e o limite do que ela estabelece

O enriquecimento observado é maior que a unidade em 174 dos 181 frames explicados, e a fração de atribuição que recai fora da máscara é consistentemente menor que a esperada sob distribuição uniforme. Isso descarta a hipótese mais grosseira: os modelos não distribuem atenção homogeneamente pelo quadro, e a concentração ocorre sobre a região térmica que contém o animal.

Esse resultado, contudo, não estabelece ausência de confundimento ambiental, e a razão é metodológica. A máscara é obtida por limiarização do canal térmico e inclui, por construção, toda a região quente do quadro. Nas imagens deste banco, isso abrange não apenas o animal, mas também as faixas mornas da esteira e das paredes da baía. A hipótese de confundimento formulada na Seção 5.1 nunca foi a de que o modelo

atenderia ao fundo frio; foi a de que atenderia à deriva térmica do equipamento, que se manifesta precisamente nas regiões quentes. A contaminação da máscara coincide, portanto, com a região sob suspeita, e o enriquecimento medido é compatível tanto com atenção ao animal quanto com atenção conjunta ao animal e à superfície aquecida do equipamento.

O que a análise estabelece é que a atribuição é espacialmente concentrada em regiões quentes; o que ela não estabelece é qual objeto quente a sustenta. Decidir entre as duas hipóteses da Seção 3.2 exigiria segmentação que separe o corpo do animal das superfícies aquecidas do equipamento, e a comparação da densidade de atribuição entre essas duas regiões. Registramos essa limitação explicitamente porque a direção do viés é conhecida: uma máscara que absorve o equipamento desloca o enriquecimento para cima, isto é, na direção de subestimar o confundimento.

Um terceiro resultado restringe adicionalmente a leitura. O enriquecimento é indistinguível entre frames corretos e incorretos, e estável entre cenários cujos desempenhos diferem por mais de 0,3 de F_1 macro. A localização espacial da atribuição, medida desta forma, não covaria com a competência do classificador — o que sugere que a diferença entre um cenário resolvido e um cenário não resolvido não está em *onde* o modelo olha.

3.4 Efeito da granularidade

Agrupar classes reduz a dificuldade da tarefa, e é esperado que o desempenho agregado suba. O resultado informativo não é essa subida, mas o fato de ela ser fortemente assimétrica entre agrupamentos de mesmo tamanho.

Os cenários TRÊS-A e TRÊS-B têm três classes cada, partem do mesmo problema de quatro classes, usam a mesma partição e diferem exclusivamente em qual par é fundido. O ganho sobre a respectiva referência é de 0,223 em TRÊS-A e 0,506 em TRÊS-B. Se o ganho refletisse apenas a simplificação combinatória da tarefa, os dois valores seriam próximos, uma vez que a redução de quatro para três classes é a mesma. A diferença observada localiza a informação ausente: o par Intenso-Severo é o que o modelo não separa, e removê-lo do problema recupera desempenho, enquanto remover o par Baixo-Moderado recupera pouco.

A leitura por classe da Tabela 3 converge com isso. No cenário QUATRO, a revocação de Severo é nula em metade dos folds e, nos folds em que não é, ocorre às custas de Intenso. No cenário TRÊS-A, que preserva a distinção, Severo permanece com revocação média de 0,195 para o Random Forest. Não se trata de uma classe difícil no sentido usual: trata-se de uma fronteira que, nas condições deste banco, o classificador não localiza.

Convém separar o que é limitação do sinal do que é limitação do desenho. Apenas quatro dos onze animais alcançaram o estágio Severo, e o protocolo rotativo retira dois deles de cada treinamento — um para teste e um para validação — deixando dois animais para representar a classe. Uma classe representada por dois indivíduos não sustenta a distinção entre aprender a classe e aprender aqueles indivíduos. A conclusão defensável, portanto, é sobre a conjunção de banco e desenho: nas condições disponíveis, a fronteira da MFEL não é recuperável a partir das imagens. Estabelecer

que ela é intrinsecamente irrecuperável exigiria uma coorte em que essa classe estivesse adequadamente representada.

3.5 Colapso na classe majoritária

O colapso ocorreu em 11 dos 32 treinamentos, apesar da ponderação de classes descrita na Seção 5.4. Sua distribuição é informativa. A rede treinada do zero colapsou nos quatro cenários; o extrator pré-treinado, apenas em TRÊS-A e BINÁRIO, e em nenhum fold de TRÊS-B.

Nos cenários agrupados, a classe fundida sublimiar concentra 74% dos frames em TRÊS-A e BINÁRIO. A ponderação inversa à frequência corrige o desbalanceamento contado em frames, mas não o desbalanceamento contado em sujeitos, que é o que efetivamente limita: os frames que reponderamos provêm de nove animais no treinamento, e uma classe rara concentrada em poucos deles continua rara em número de observações independentes, por mais que o peso a amplifique [Castro and Braga \(2011\)](#).

Esse é o mesmo fenômeno já discutido para o par Intenso-Severo, observado por outro instrumento, e reforça que o tamanho efetivo da amostra deste banco é o número de sessões, não o número de imagens. O colapso é reportado por fold na Tabela 1, e não apenas de forma agregada, precisamente porque um classificador degenerado pode registrar F_1 ponderado não trivial sob desbalanceamento forte.

3.6 Limitações

As três limitações estruturais do desenho foram enunciadas na Seção 5.9; retomamos aqui apenas suas consequências para a leitura dos resultados.

A estimativa de teste repousa sobre quatro animais, e essa é a fonte dominante de incerteza. Os intervalos da Tabela 2 refletem reamostragem dessas quatro estimativas em nível de sujeito e são, por construção, largos — em QUATRO, o intervalo do Random Forest cobre de 0,322 a 0,598. Intervalos estreitos, sob esta base amostral, seriam sinal de que a unidade de reamostragem está errada, e não de precisão. Pelo mesmo motivo, e conforme antecipado na Seção 5.6, não reportamos p -valores para as comparações entre modelos: com quatro folds, um teste pareado bilateral não pode retornar valor inferior a 0,125, e reportá-lo sob essa restrição induziria conclusão em qualquer direção [Demšar \(2006\)](#).

A restrição aos quatro animais completos foi mantida também nos cenários agrupados, onde não seria necessária. A escolha preserva a comparabilidade entre cenários, que é o eixo do estudo, ao custo de condicionar as estimativas de TRÊS-B e BINÁRIO aos animais que correram por mais tempo. Como esses são os animais de melhor desempenho aeróbio, as estimativas desses dois cenários não devem ser lidas como estimativas sobre a coorte completa.

Todas as sessões foram registradas em um único ambiente, com posição de câmera fixa. A transferência das representações aprendidas para outras montagens de aquisição não é avaliada por este desenho, e a análise de atribuição incide sobre essa questão apenas indiretamente, pelas razões dadas na Seção 3.3.

3.7 Sobre o classificador acoplado ao extrator

O Random Forest ajustado sobre os descritores da ResNet50 não se distingue, em três dos quatro cenários, da cabeça linear treinada no mesmo backbone, e é superado por ela no cenário binário. O resultado é coerente com a estrutura do procedimento: o primeiro estágio otimiza a representação por entropia cruzada sobre uma cabeça linear, o que molda os descritores para serem linearmente separáveis. Um classificador de viés indutivo distinto, ajustado posteriormente sobre um espaço já organizado nesses termos, tem pouca margem adicional a explorar.

A implicação prática é que o desempenho observado nesta família deve ser atribuído à representação transferida, e não ao classificador acoplado a ela. Reportamos a cabeça linear na Tabela 2 por essa razão: sem ela, o ganho da transferência de aprendizado e o ganho do classificador não são separáveis.

4 Conclusão

Avaliamos, sob partição em nível de sujeito, se imagens termográficas de roedores em esteira sustentam a classificação de domínios de intensidade de exercício em animais não vistos. A resposta é afirmativa em uma granularidade grosseira e negativa na granularidade fisiologicamente relevante.

Na decisão binária entre domínios subliminares e supraliminares, o melhor modelo alcança F_1 macro de 0,881, contra 0,378 da predição da classe majoritária. Há sinal térmico associado à intensidade que sobrevive à troca de indivíduo. Na separação de quatro classes, o mesmo protocolo alcança 0,460, contra 0,117 da referência — acima do acaso, porém com a classe Severo não recuperada em metade dos folds.

O resultado que melhor caracteriza o limite encontrado é a assimetria entre os dois agrupamentos de três classes. Fundir a fronteira da MFEL rende mais que o dobro do ganho de fundir a fronteira do limiar aeróbio, sob partição idêntica e mesma redução no número de classes. A informação ausente concentra-se em uma única fronteira, e é justamente a de maior consequência prática.

A análise de atribuição estabelece que a atenção dos modelos é espacialmente concentrada sobre regiões quentes do quadro, e não difusa. Não estabelece, porém, que essa concentração recaia sobre o animal e não sobre superfícies aquecidas do equipamento, porque a máscara empregada não separa os dois. A questão do confundimento ambiental permanece, assim, parcialmente aberta.

Estas conclusões são condicionadas aos quatro animais que compuseram os conjuntos de teste e ao ambiente único de aquisição, e não devem ser estendidas à população de roedores nem a outras montagens experimentais.

Quatro direções decorrem diretamente das limitações identificadas. A primeira, e única que eleva o poder estatístico, é a ampliação da coorte, com atenção particular ao número de animais que alcançam o estágio Severo — a restrição que domina todos os resultados aqui reportados. A segunda é a aquisição em ambientes e montagens variados, que permitiria avaliar a transferência das representações e, simultaneamente, discriminar sinal fisiológico de deriva do equipamento. A terceira é a segmentação do animal como pré-processamento, que tornaria a análise de atribuição conclusiva e permitiria treinar modelos sobre imagens com fundo removido, verificando diretamente

quanto do desempenho sobrevive à remoção. A quarta é o tratamento explícito da estrutura ordinal dos rótulos: com aproximadamente 90% dos erros recaindo sobre classes adjacentes, uma formulação ordinal — por perda ordinal ou por regressão com limiares — é diretamente motivada pelos dados, ainda que não altere a limitação de fundo, que é amostral.

5 Materiais e Métodos

Esta seção descreve o banco de imagens termográficas (Seção 5.1), os agrupamentos de rótulos avaliados (Seção 5.2), o protocolo de particionamento (Seção 5.3), os modelos de classificação (Seção 5.4), o procedimento de seleção de modelos (Seção 5.5), as métricas e a estimação de incerteza (Seção 5.6) e a análise de atribuição empregada para verificar *onde* na imagem os modelos buscam evidência (Seção 5.7).

5.1 Banco de imagens termográficas

O banco de dados foi construído a partir de vídeos termográficos de sessões de corrida em esteira com roedores. Este estudo não conduziu experimentos com animais: as sessões foram realizadas em 2019 por pesquisadores do Laboratório de Fisiologia Aplicada ao Esporte (LAFAE) da Faculdade de Ciências Aplicadas (FCA) da Universidade Estadual de Campinas (UNICAMP), sob a respectiva aprovação do comitê institucional de ética animal.

Quatorze ratos machos da linhagem Wistar foram criados em conjunto e alimentados com dieta idêntica. Previamente à gravação, cada animal passou por sessões preliminares nas quais a concentração de lactato sanguíneo foi medida de forma invasiva, a fim de determinar as velocidades de esteira correspondentes a cada domínio de intensidade individualmente. Essa individualização é o que confere significado fisiológico aos rótulos: um mesmo estágio nominal corresponde a uma velocidade absoluta distinta para cada animal, procedimento consolidado em modelos de roedores [Gobatto et al. \(2001\)](#); [Manchado et al. \(2006\)](#); [Orsi et al. \(2023\)](#).

Os vídeos foram registrados com uma câmera termográfica FLIR One Pro posicionada a 28 cm acima da esteira; a baía de corrida media 9,1 cm de largura, 8 cm de altura e 18 cm de comprimento. A gravação iniciava no instante em que a esteira era acionada e cessava quando o animal parava de correr.

Cada sessão compreendia quatro estágios consecutivos de três minutos, que definem os quatro rótulos:

- **Baixo** — intensidade de aquecimento; frames de 0 s a 180 s;
- **Moderado** — intensidade no limiar aeróbio (limiar de lactato); frames de 181 s a 360 s;
- **Intenso** — intensidade na máxima fase estável de lactato (MFEL); frames de 361 s a 540 s;
- **Severo** — intensidade 20 % acima da MFEL; frames posteriores a 540 s.

Essa partição do contínuo de esforço em domínios delimitados por transições metabólicas segue a formulação clássica da fisiologia do exercício [Gaesser and Poole \(1996\)](#); [Beneke \(2003\)](#); [Billat et al. \(2003\)](#); [Faude et al. \(2009\)](#); [Jamnick et al. \(2020\)](#),

e o uso de roedores como modelo experimental para essas transições é sustentado pela similaridade dos mecanismos fisiológicos de resposta ao esforço [Booth et al. \(2010\)](#); [Kemi and Wisløff \(2010\)](#); [Scariot et al. \(2023\)](#).

Um animal não correu e foi excluído, e dois animais não participaram do protocolo; os onze animais restantes receberam identificadores de 1 to 11. Nem todas as sessões alcançaram o quarto estágio, pois alguns animais interromperam a corrida antes. A extração de frames e a rotulação por janela temporal produziram 32.014 imagens, das quais 196 foram removidas manualmente por conterem interferência do operador (mão ou braço no campo de visão), resultando em 31.818 imagens. A distribuição de classes é acentuadamente desbalanceada (Tabela 6): Baixo 38,16 %, Moderado 35,94 %, Intenso 21,53 % e Severo 4,37 %.

Table 6 Número de imagens por classe e disponibilidade da classe por sujeito. Apenas quatro animais (1, 9, 10 e 11) contribuíram com frames para as quatro classes.

Classe	Imagens	Sujeitos contribuintes
Baixo	12.141	11
Moderado	11.436	11
Intenso	6.850	10
Severo	1.391	4
Total	31.818	11

Duas propriedades estruturais deste banco governam todas as decisões metodológicas subsequentes, e as explicitamos porque são fáceis de perder de vista uma vez que os dados estejam armazenados como uma coleção plana de imagens.

Frames não são amostras independentes.

As imagens são frames consecutivos de vídeo amostrados à taxa da câmera. Dois frames separados por poucos centésimos de segundo diferem apenas pela fase da passada e por ruído do sensor; para fins de modelagem, são quase-duplicatas. O número efetivo de observações independentes está, portanto, mais próximo do número de *sessões* (onze) do que do número de imagens (31.818).

A classe é confundida com o tempo decorrido e com o sujeito.

Como os rótulos são definidos por janelas temporais dentro de uma sessão, a identidade da classe é perfeitamente colinear ao tempo de gravação, e todos os frames de uma dada classe em uma sessão provêm do mesmo animal no mesmo estado térmico. Qualquer pista que varie monotonicamente ao longo da sessão — aquecimento da superfície da esteira, condensação, deriva da câmera, desarranjo progressivo da pelagem — fica disponível ao classificador como atalho para o rótulo.

5.2 Agrupamentos de rótulos

Foram avaliados quatro cenários de rotulação, do problema completo de quatro classes até uma decisão binária. Eles diferem apenas pelo mapa de rótulos aplicado ao manifesto; as imagens, as partições e o procedimento de treinamento são idênticos entre cenários.

Table 7 Agrupamentos de rótulos avaliados.

Cenário	Classes	Agrupamento
QUATRO	Baixo · Moderado · Intenso · Severo	nenhum
TRÊS-A	[Baixo, Moderado] · Intenso · Severo	une os dois domínios sublimiares
TRÊS-B	Baixo · Moderado · [Intenso, Severo]	une os dois domínios supralimiares
BINÁRIO	[Baixo, Moderado] · [Intenso, Severo]	sub- <i>vs.</i> supra-MFEL

O agrupamento TRÊS-A é motivado pela reduzida relevância prática de distinguir aquecimento de intensidade no limiar aeróbio, ao passo que TRÊS-B e BINÁRIO isolam a fronteira da MFEL, que é a transição fisiologicamente decisiva [Beneke \(2003\)](#); [Jamnick et al. \(2020\)](#) e aquela cuja classificação incorreta acarreta maior custo prático.

5.3 Protocolo de particionamento

5.3.1 Fundamentação

Dadas as duas propriedades enunciadas na Seção 5.1, o protocolo de particionamento não é um detalhe periférico de implementação: ele determina o que os números reportados de fato estimam.

Uma partição sorteada uniformemente sobre frames individuais coloca quase-duplicatas de praticamente todo frame de teste no conjunto de treinamento. O modelo pode então atingir escores elevados memorizando a aparência específica da sessão, sem aprender qualquer correlato térmico da intensidade de exercício, e a estimativa resultante responde à pergunta “o modelo reconhece um frame que já viu?” em vez da pergunta de interesse. Essa forma de vazamento é bem documentada sempre que as amostras provêm de fontes agrupadas temporalmente ou por sujeito [Kaufman et al. \(2012\)](#); [Saeb et al. \(2017\)](#); [Little et al. \(2017\)](#), constitui uma das falhas metodológicas recorrentes em aprendizado de máquina aplicado a imagens médicas [Varoquaux and Cheplygina \(2022\)](#) e foi identificada em centenas de publicações ao longo de dezessete disciplinas [Kapoor and Narayanan \(2023\)](#).

A magnitude do efeito é substancial. Em classificação de imagens de ressonância magnética, o particionamento no nível de fatias — estruturalmente análogo ao particionamento no nível de frames adotado aqui — elevou artificialmente a acurácia de teste entre 29 % e 55 % conforme a base, e, em um experimento de controle com rótulos aleatórios, produziu cerca de 96 % de acurácia onde o particionamento por sujeito produziu os 50 % esperados do acaso [Yagis et al. \(2021\)](#). Ou seja, sob particionamento no nível da unidade errada, um conjunto de dados sem qualquer sinal pode parecer quase perfeitamente classificável.

Adotamos, portanto, **particionamento em nível de sujeito** em todo o trabalho: todos os frames de um mesmo animal são atribuídos a exatamente um dos conjuntos de treinamento, validação ou teste, nunca divididos entre eles. A quantidade estimada passa a ser o desempenho sobre um *animal não visto*, que é a operacionalmente relevante — um sistema em uso é aplicado a novos indivíduos, e não a instantes inéditos de um indivíduo com que já foi treinado [Saeb et al. \(2017\)](#).

5.3.2 Construção dos folds

O particionamento em nível de sujeito, isoladamente, não basta. Com onze sujeitos, uma única divisão treino/teste produz um animal de teste e, portanto, uma estimativa pontual sem qualquer medida da variabilidade entre indivíduos, deixando o leitor sem meios de distinguir um efeito real da idiossincrasia de um animal [Varoquaux and Cheplygina \(2022\)](#). Adotamos, por isso, um esquema rotativo.

Apenas quatro animais (1, 9, 10 e 11) contribuíram com frames para as quatro classes (Tabela 6); os sete restantes interromperam a corrida antes de alcançar o estágio Severo. Um conjunto de teste formado por um animal incompleto não pode pontuar as classes ausentes, e um conjunto de validação formado por um animal incompleto não pode ser usado para selecionar modelo sob critério balanceado entre classes. Definimos, assim, um **protocolo rotativo pareado** sobre esses quatro sujeitos completos: no fold i , o sujeito s_i compõe o conjunto de teste, o sujeito $s_{(i+1) \bmod 4}$ compõe o conjunto de validação, e os nove animais restantes compõem o treinamento. Disso resultam quatro folds:

Table 8 Os quatro folds. Cada sujeito completo atua uma vez como teste e uma vez como validação; o treinamento compreende sempre os nove animais restantes.

Fold	Teste	Validação	Treinamento
1	{1}	{9}	nove restantes
2	{9}	{10}	nove restantes
3	{10}	{11}	nove restantes
4	{11}	{1}	nove restantes

Duas propriedades deste desenho merecem menção explícita.

Primeiro, a validação também é disjunta do treinamento em nível de sujeito. A parada antecipada, o escalonamento da taxa de aprendizado e a escolha de hiperparâmetros são todos conduzidos pelo escore de validação; se os frames de validação proviessem de animais de treinamento, essas decisões seriam tomadas sobre dados vazados e a estimativa de teste herdaria o otimismo, ainda que o próprio conjunto de teste estivesse limpo [Little et al. \(2017\)](#).

Segundo, **os mesmos quatro folds são usados nos quatro cenários de rotação**. Sob os agrupamentos da Tabela 7, a noção de sujeito “completo” muda — no cenário BINÁRIO, por exemplo, todos os onze animais contêm ambas as classes —,

de modo que uma partição derivada automaticamente produziria folds distintos por cenário e os cenários deixariam de ser comparáveis. Fixar os folds faz com que as diferenças entre cenários sejam atribuíveis exclusivamente ao mapa de rótulos. O custo é que, nos cenários agrupados, a estimativa permanece condicionada aos quatro animais de melhor desempenho; retomamos esse ponto na Seção 5.9.

5.4 Modelos

Foram avaliadas duas famílias de modelos. Ambas recebem representações RGB de 224×224 dos frames termográficos, com valores de pixel escalados para $[0, 1]$ e normalizados pelas estatísticas de canal do ImageNet [Deng et al. \(2009\)](#).

5.4.1 Rede convolucional treinada do zero

Uma rede neural convolucional [LeCun et al. \(2015\)](#) com 403.936 parâmetros treináveis no cenário de quatro classes. A arquitetura compreende quatro blocos convolucionais com 2, 4, 8 e 16 filtros de tamanho 3×3 e padding `same`, cada um seguido de ativação ReLU e *average pooling* 2×2 ; uma camada de normalização em lote [Ioffe and Szegedy \(2015\)](#) sobre os 16 mapas resultantes; o achatamento desses mapas em um vetor de 3.136 dimensões; uma camada densa de 128 unidades com ativação ReLU e normalização em lote; e uma camada de saída com uma unidade por classe. As matrizes de pesos das camadas convolucionais são regularizadas por penalidades combinadas L_1 (10^{-5}) e L_2 (10^{-4}), somadas explicitamente à função de perda e não aplicadas por decaimento de pesos do otimizador, de modo a não incidirem sobre vieses nem sobre parâmetros de normalização.

A especificação de origem dessa arquitetura é ambígua: a legenda e a tabela da figura que a descreve divergem quanto ao número de blocos e à largura das camadas. Adotamos a variante da tabela, que é a única com a qual a contagem declarada de parâmetros fecha na resolução nativa das imagens. Como o presente trabalho opera a 224×224 , o achatamento resulta em 3.136 dimensões em vez das 6.688 da resolução original, e a contagem total de parâmetros muda na mesma proporção.

Ambas as famílias são treinadas com o otimizador Adam [Kingma and Ba \(2015\)](#), entropia cruzada categórica como função de perda, lotes de 32 imagens e no máximo 200 épocas, com três mecanismos monitorando o F_1 macro de validação: redução da taxa de aprendizado em 90% após um número fixo de épocas sem melhora, parada antecipada após um segundo número de épocas sem melhora, e restauração dos pesos correspondentes ao melhor score de validação para avaliação. Os valores diferem entre as famílias, conforme a Tabela 9; as paciências mais largas na rede treinada do zero refletem sua convergência mais lenta e ruidosa.

Os pesos de classe são recalculados por fold e por cenário [Castro and Braga \(2011\)](#), uma vez que a composição do conjunto de treinamento muda com o sujeito retido. A rede convolucional emprega o esquema $N_{\max}/N_c$, onde $N_{\max}$ é a contagem da classe mais frequente e N_c a da classe c ; o extrator pré-treinado emprega $N/(k \cdot N_c)$, onde N é o total de frames e k o número de classes.

Table 9 Hiperparâmetros de treinamento efetivamente empregados em cada família de modelo.

	Rede convolucional	ResNet50 + RF
Taxa de aprendizado inicial	10^{-3}	10^{-4}
Decaimento de pesos	—	10^{-4}
Paciência (redução da taxa)	15	6
Paciência (parada antecipada)	45	15
Fator de redução da taxa	0,1	0,1
Tamanho do lote	32	32
Épocas máximas	200	200
Esquema de pesos de classe	$N_{\max}/N_c$	$N/(k \cdot N_c)$

A rede convolucional dispensa decaimento de pesos porque a regularização é dada pelas penalidades L_1 e L_2 sobre as camadas convolucionais.

5.4.2 Extrator pré-treinado com classificador Random Forest

Uma ResNet50 [He et al. \(2016\)](#) pré-treinada no ImageNet [Deng et al. \(2009\)](#), com todas as camadas congeladas exceto o último estágio residual (`layer4`), que é ajustado sobre a partição de treinamento — estratégia de transferência de aprendizado [Weiss et al. \(2016\)](#) que preserva as representações genéricas de baixo nível e adapta apenas as de alto nível ao domínio termográfico [He et al. \(2021\)](#). O *global average pooling* sobre os mapas finais produz um descritor de 2.048 dimensões por imagem. Os descritores são padronizados (média zero, variância unitária, com estatísticas estimadas apenas sobre a partição de treinamento) e usados para ajustar um classificador Random Forest [Breiman \(2001\)](#) com 100 árvores, pesos de classe balanceados e mínimo de 5 amostras por folha.

O ajuste supervisionado do primeiro estágio produz, como subproduto, um classificador linear sobre o mesmo descritor de 2.048 dimensões — a camada totalmente conectada treinada em conjunto com o último estágio residual. Esse classificador é avaliado e reportado separadamente. Ele não constitui um modelo adicional: compartilha o *backbone*, os folds e o conjunto de teste com a variante Random Forest, e é a referência direta contra a qual o ganho do classificador acoplado deve ser medido. Sem ela, o efeito da representação transferida e o efeito do classificador ajustado sobre ela não são separáveis. O Random Forest não é diferenciável, de modo que o ajuste ocorre necessariamente em dois estágios: não há gradiente que retorne do classificador para as camadas convolucionais.

Ajustar o padronizador apenas sobre a partição de treinamento — e não sobre o banco completo — é deliberado: estatísticas calculadas sobre todos os frames codificariam informação do animal retido na representação, constituindo uma forma mais sutil do vazamento discutido na Seção 5.3 [Kaufman et al. \(2012\)](#).

5.5 Seleção de modelos

Os hiperparâmetros foram selecionados por fold, exclusivamente sobre o sujeito de validação; o sujeito de teste não foi consultado em nenhum momento antes da avaliação final.

Uma análise preliminar de sensibilidade sobre a grade completa de hiperparâmetros (taxa de aprendizado, decaimento de pesos, *dropout* e tamanho de lote para a rede convolucional; número de árvores, profundidade máxima e mínimo de amostras por folha para o Random Forest) mostrou que nenhum hiperparâmetro isolado deslocou o F_1 macro de validação além do desvio-padrão entre folds (0,081 para a rede convolucional, 0,074 para ResNet50 + RF). Em outras palavras, a escolha de hiperparâmetro não é identificável diante da variabilidade entre sujeitos deste banco, e uma busca exaustiva produziria uma seleção guiada por ruído, e não por sinal. A grade foi consequentemente reduzida a dois candidatos por família de modelo, que reportamos explicitamente em vez de apresentar uma busca ampla cujo resultado os dados não sustentam Varoquaux and Cheplygina (2022).

5.6 Métricas e incerteza

Dado o desbalanceamento de classes, a acurácia não é reportada como métrica primária: um classificador que preveja a classe majoritária para todo frame atingiria 38,16% de acurácia no cenário de quatro classes sendo clinicamente inútil Castro and Braga (2011). Reportamos como métrica primária o F_1 macro, acompanhado da acurácia balanceada Brodersen et al. (2010) e de revocação, precisão e F_1 por classe. A revocação é reportada em separado para Intenso e Severo porque um falso negativo nessas classes — deixar de detectar um animal em estado de alto estresse — é o erro de maior consequência na aplicação pretendida Davis and Goadrich (2006). Matrizes de confusão completas são fornecidas para todos os folds e cenários.

Colapso na classe majoritária.

Reportamos adicionalmente, para cada fold, se o modelo degenerou para a predição de uma única classe. Um classificador degenerado pode registrar F_1 ponderado não trivial sob desbalanceamento forte, e reportar apenas métricas agregadas ocultaria esse modo de falha.

Adjacência dos erros.

Os quatro rótulos estão ordenados ao longo de um contínuo fisiológico, de modo que confundir Intenso com Severo é um erro materialmente distinto de confundir Baixo com Severo. Reportamos, portanto, a proporção de classificações incorretas que recaem sobre classes adjacentes. Uma taxa alta de adjacência é compatível tanto com similaridade térmica genuína entre domínios vizinhos quanto com o modelo rastreando o tempo decorrido de sessão em vez da intensidade; é a análise de atribuição da Seção 5.7 que distingue as duas hipóteses.

Incerteza.

Os intervalos de confiança foram obtidos por reamostragem *bootstrap* percentil Efron and Tibshirani (1993) em nível de sujeito, não em nível de frame. Reamostrar frames traria 31.818 quase-duplicatas como sorteios independentes e produziria intervalos mais estreitos que a incerteza real por aproximadamente a raiz quadrada do número de frames por animal.

Como o protocolo rotativo atribui um único animal ao conjunto de teste de cada fold, a reamostragem não é conduzida dentro do fold — um único sujeito não gera variabilidade —, e sim sobre o conjunto das quatro estimativas de fold, cada uma proveniente de um animal distinto. Os intervalos reportados refletem, portanto, a base efetiva da estimativa: quatro animais de teste. São largos por construção, e essa largura é o resultado honesto do desenho, não uma deficiência do procedimento; intervalos estreitos sobre esta base amostral indicariam que a unidade de reamostragem está errada.

Sobre testes de significância.

Com quatro folds, um teste de Wilcoxon pareado bilateral [Wilcoxon \(1945\)](#) não pode retornar p inferior a 0,125, independentemente de quão grande ou consistente seja a diferença observada — limitação de potência inerente a comparações com poucas partições [Demšar \(2006\)](#). Reportar p -valores sob essa restrição seria enganoso em qualquer direção: um efeito genuíno não pode alcançar significância convencional, e um resultado nulo não carrega peso evidencial. Reportamos, portanto, as diferenças por fold, sua direção e consistência, e intervalos *bootstrap* em nível de sujeito, e não reportamos p -valores para a comparação entre modelos. Trata-se de uma escolha deliberada de reporte, não de uma omissão [Varoquaux and Cheplygina \(2022\)](#).

5.7 Análise de atribuição

O confundimento descrito na Seção 5.1 levanta uma preocupação específica: um modelo poderia alcançar acurácia não trivial atendendo à superfície da esteira — que se aquece ao longo da sessão — em vez do animal. Métricas de desempenho, isoladamente, não distinguem esse caso de sinal fisiológico genuíno.

Computamos, portanto, atribuições SHAP [Lundberg and Lee \(2017\)](#); [Winter \(2002\)](#) para o melhor modelo de cada família sobre o sujeito de teste de cada fold, e quantificamos sua distribuição espacial em relação a uma máscara binária do animal obtida por limiarização do canal térmico.

Reportar a fração de atribuição que recai sobre o fundo é insuficiente por si só, pois o animal ocupa fração pequena do quadro: um modelo que atribuísse uniformemente ao acaso concentraria a maior parte da atribuição no fundo apenas por área. Reportamos, por isso, o **enriquecimento de atribuição** E , razão entre a densidade de atribuição dentro da máscara do animal e a densidade fora dela:

$$E = \frac{\sum_{p \in A} |\phi_p| / |A|}{\sum_{p \in B} |\phi_p| / |B|}, \quad (1)$$

onde ϕ_p é o valor SHAP do pixel p , A é o conjunto de pixels internos à máscara do animal e B seu complemento. $E = 1$ indica atribuição indistinguível da uniforme; $E > 1$ indica atenção preferencial ao animal.

A máscara é obtida por limiarização de Otsu sobre o canal térmico $R-B$, calculada independentemente para cada frame. O limiar adaptativo é preferível a um quantil

fixo porque a fração do quadro ocupada pelo animal varia substancialmente entre indivíduos e entre frames de um mesmo indivíduo. Registramos que essa máscara delimita a região quente do quadro, e não o corpo do animal: superfícies aquecidas do equipamento — notadamente as faixas laterais da baia — podem ser incluídas. O viés resultante tem direção conhecida: atribuição que recaia sobre o equipamento aquecido é contabilizada dentro da máscara, o que desloca E para cima. Os valores reportados são, portanto, um limite superior para a atenção efetivamente dirigida ao animal, e a Seção 3.3 retoma o que isso permite e o que não permite concluir.

Como o Random Forest não admite atribuição em nível de pixel, a análise para essa família incide sobre a rede com a cabeça linear, que compartilha com ela o mesmo *backbone* e a mesma representação.

5.8 Implementação e reprodutibilidade

O pipeline foi implementado em Python, com PyTorch [Paszke et al. \(2019\)](#) para os modelos neurais e scikit-learn [Pedregosa et al. \(2011\)](#) para o Random Forest, a padronização e os procedimentos de reamostragem. Está organizado em estágios independentes — construção do manifesto, particionamento, montagem do conjunto de dados, definição dos modelos, treinamento, busca de hiperparâmetros, atribuição e agregação —, cada um gravando artefato explícito em disco, de modo que qualquer estágio possa ser auditado ou reexecutado sem reexecutar os demais. A configuração resolvida de cada execução, incluindo a semente aleatória e a atribuição exata de sujeitos de cada fold, é serializada junto às suas saídas. Os resultados de cada cenário de rotulação são gravados em diretório separado, e a partição é gerada uma única vez e reutilizada, de modo que os quatro cenários são verificavelmente avaliados sobre folds idênticos.

Sementes aleatórias foram fixadas para o particionamento, a inicialização de pesos e a construção do Random Forest. Registramos que a reprodutibilidade bit a bit do treinamento em GPU não é garantida apenas pela fixação de sementes, dada a seleção não determinística de *kernels* na cuDNN; a variabilidade entre folds reportada é substancialmente maior que essa fonte de variação.

5.9 Escopo e limitações do desenho

Três limitações decorrem diretamente do desenho e são enunciadas aqui, e não na discussão, por delimitarem o que os resultados da Seção 2 podem sustentar.

Primeira, a estimativa de teste repousa sobre quatro animais. Esse é o número de sujeitos do banco que alcançaram os quatro domínios de intensidade, e nenhum esquema de particionamento pode aumentá-lo. A variabilidade entre sujeitos é, conseqüentemente, a fonte dominante de incerteza, e é o que os intervalos *bootstrap* da Seção 5.6 reportam.

Segunda, nos cenários agrupados (TRÊS-B e BINÁRIO) um número maior de animais qualificaria como completo, e um protocolo *leave-one-subject-out* sobre dez ou onze animais seria viável. Mantivemos deliberadamente os mesmos quatro folds para

preservar a comparabilidade entre cenários; as estimativas desses cenários estão, portanto, condicionadas aos quatro animais que correram por mais tempo, e não devem ser lidas como estimativas sobre a coorte completa.

Terceira, todas as sessões foram registradas em um único ambiente, com posição de câmera fixa. O quanto as representações aprendidas transferem entre diferentes montagens de aquisição não é abordado por este desenho, e a análise de atribuição da Seção 5.7 incide sobre a questão apenas indiretamente Varoquaux and Cheplygina (2022).

Agradecimentos. Os autores agradecem ao Laboratório de Fisiologia Aplicada ao Esporte (LAFAE) da Faculdade de Ciências Aplicadas da UNICAMP pela condução das sessões experimentais que originaram o banco de imagens utilizado neste estudo. [\[\[Acreditar agências de fomento e números de processo.\]\]](#)

Declarações

Financiamento. [\[\[Agências e números de processo.\]\]](#)

Conflito de interesses. Os autores declaram não haver conflito de interesses.

Aprovação ética. Este estudo não conduziu experimentos com animais. As sessões de corrida foram realizadas em 2019 por pesquisadores do Laboratório de Fisiologia Aplicada ao Esporte (LAFAE) da Faculdade de Ciências Aplicadas da UNICAMP, sob aprovação do comitê institucional de ética no uso de animais [\[\[número do protocolo CEUA\]\]](#).

Disponibilidade de dados e código. O código do pipeline de avaliação, incluindo os arquivos de configuração que reproduzem as partições e os experimentos aqui reportados, está disponível em [\[\[URL do repositório\]\]](#). O banco de imagens termográficas [\[\[condições de acesso: público, mediante solicitação aos autores, ou restrito\]\]](#).

Contribuição dos autores. **Pedro Bernini:** conceituação, metodologia, investigação, redação — rascunho original. **Guilherme Henrique Rodrigues:** metodologia, *software*, validação, análise formal, curadoria de dados, visualização, redação — revisão e edição. Responsável pelo desenho do protocolo de avaliação em nível de sujeito, pela implementação do *pipeline* e pela execução dos experimentos. **Fúlvia Barros Manchado Gobatto:** recursos, investigação, redação — revisão e edição. **Claudio Alexandre Gobatto:** recursos, investigação, redação — revisão e edição. **André Franceschi Angelis:** supervisão, redação — revisão e edição. **Ulisses Dias:** supervisão, administração do projeto, redação — revisão e edição. [\[\[Confirmar a atribuição CRediT dos demais autores com o grupo.\]\]](#)

References

Goncalves, C., Raimundo, A., Abreu, A., Bravo, J.: Exercise intensity in patients with cardiovascular diseases: systematic review with meta-analysis. *International Journal of Environmental Research and Public Health* **18**(7), 3574 (2021)

- Gaesser, G.A., Poole, D.C.: The slow component of oxygen uptake kinetics in humans. *Exercise and Sport Sciences Reviews* **24**(1), 35–70 (1996)
- Poole, D.C., Richardson, R.S.: Determinants of oxygen uptake: implications for exercise testing. *Sports Medicine* **24**(5), 308–320 (1997)
- Beneke, R.: Methodological aspects of maximal lactate steady state: implications for performance testing. *European Journal of Applied Physiology* **89**(1), 95–99 (2003)
- Billat, V.L., Sirvent, P., Py, G., Koralsztein, J.-P., Mercier, J.: The concept of maximal lactate steady state: a bridge between biochemistry, physiology and sport science. *Sports Medicine* **33**(6), 407–426 (2003)
- Faude, O., Kindermann, W., Meyer, T.: Lactate threshold concepts: how valid are they? *Sports Medicine* **39**(6), 469–490 (2009)
- Iannetta, D., Qahtani, A., Millet, G.Y., Murias, J.M.: Quadriceps muscles O₂ extraction and EMG breakpoints during a ramp incremental test. *Frontiers in Physiology* **8**, 686 (2017)
- Perrey, S., Quaresima, V., Ferrari, M.: Muscle oximetry in sports science: an updated systematic review. *Sports Medicine* **54**(4), 975–996 (2024)
- Jamnick, N.A., Pettitt, R.W., Granata, C., Pyne, D.B., Bishop, D.J.: An examination and critique of current methods to determine exercise intensity. *Sports Medicine* **50**(10), 1729–1756 (2020)
- Gomez-Carmona, P., Fernández-Cuevas, I., Sillero-Quintana, M., Arnaiz-Lastras, J., Navandar, A.: Infrared thermography protocol on reducing the incidence of soccer injuries. *Journal of Sport Rehabilitation* **29**(8), 1222–1227 (2020)
- Hildebrandt, C., Raschner, C., Ammer, K.: An overview of recent application of medical infrared thermography in sports medicine in Austria. *Sensors* **10**(5), 4700–4715 (2010)
- Masur, L., Brand, F., Düking, P.: Response of infrared thermography related parameters to (non-)sport specific exercise and relationship with internal load parameters in individual and team sport athletes: a systematic review. *Frontiers in Sports and Active Living* **6**, 1479608 (2024)
- Da Silva, W., Godoy-López, J.R., Machado, Á.S., Lemos, A.L., Sendra-Pérez, C., Brejano, M.G., Carpes, F.P., Priego-Quesada, J.I.: Effect of different volumes of exercise on skin temperature responses over the following 24 hours. *Journal of Thermal Biology* **123**, 103923 (2024)
- LeCun, Y., Bengio, Y., Hinton, G.: Deep learning. *Nature* **521**(7553), 436–444 (2015)
- Cañada-Soriano, M., Bovaira, M., Garcia-Vitoria, C., Salvador-Palmer, R., Anda, R.,

- Moratal, D., Priego-Quesada, J.I.: Application of machine learning algorithms in thermal images for an automatic classification of lumbar sympathetic blocks. *Journal of Thermal Biology* **113**, 103523 (2023)
- He, Y., Deng, B., Wang, H., Cheng, L., Zhou, K., Cai, S., Ciampa, F.: Infrared machine vision and infrared thermography with deep learning: a review. *Infrared Physics & Technology* **116**, 103754 (2021)
- Gobatto, C.A., De Mello, M.A.R., Sibuya, C.Y., De Azevedo, J.R.M., Dos Santos, L.A., Kokubun, E.: Maximal lactate steady state in rats submitted to swimming exercise. *Comparative Biochemistry and Physiology Part A: Molecular & Integrative Physiology* **130**(1), 21–27 (2001)
- Booth, F.W., Roberts, C.K., Laye, M.J.: Lack of exercise is a major cause of chronic diseases. *Comprehensive Physiology* **2**(2), 1143–1211 (2010)
- Kemi, O.J., Wisløff, U.: Cardiac adaptations to exercise training: insights from animal studies. *Progress in Cardiovascular Diseases* **52**(4), 287–296 (2010)
- Orsi, J.B., Araujo, L.S., Scariot, P.P., Polisel, E.E., Cardoso, L.O., Gobatto, C.A., Manchado-Gobatto, F.B.: Critical velocity, maximal lactate steady state, and muscle MCT1 and MCT4 after exhaustive running in mice. *International Journal of Molecular Sciences* **24**(21), 15753 (2023)
- Bennett, G.J., Ochoa, J.: Thermographic observations on rats with experimental neuropathic pain. *Pain* **45**(1), 61–67 (1991)
- Scariot, P.P.M., Papoti, M., Polisel, E.E.C., Orsi, J.B., Van Ginkel, P.R., Prolla, T.A., Manchado-Gobatto, F.B., Gobatto, C.A.: Living high-training low model applied to C57BL/6J mice: effects on physiological parameters related to aerobic fitness and acid-base balance. *Life Sciences* **317**, 121443 (2023)
- Kaufman, S., Rosset, S., Perlich, C., Stitelman, O.: Leakage in data mining: formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data* **6**(4), 1–21 (2012) <https://doi.org/10.1145/2382577.2382579>
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D.C., Kording, K.P.: The need to approximate the use-case in clinical machine learning. *GigaScience* **6**(5), 1–9 (2017) <https://doi.org/10.1093/gigascience/gix019>
- Yagis, E., Atnafu, S.W., Herrera, A., Marzi, C., Sceda, R., Giannelli, M., Tessa, C., Citi, L., Diciotti, S.: Effect of data leakage in brain MRI classification using 2D convolutional neural networks. *Scientific Reports* **11**(1), 22544 (2021) <https://doi.org/10.1038/s41598-021-01681-w>
- Kapoor, S., Narayanan, A.: Leakage and the reproducibility crisis in machine-learning-based science. *Patterns* **4**(9), 100804 (2023) <https://doi.org/10.1016/j.patter.2023.100804>

- Varoquaux, G., Cheplygina, V.: Machine learning for medical imaging: methodological failures and recommendations for the future. *npj Digital Medicine* **5**(1), 48 (2022) <https://doi.org/10.1038/s41746-022-00592-y>
- Lundberg, S.M., Lee, S.-I.: A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems* 30, pp. 4765–4774 (2017)
- Verderber, L., Da Silva, W., Aparicio-Aparicio, I., Germano, A.M., Carpes, F.P., Priego-Quesada, J.I.: Assessment of alternative metrics in the application of infrared thermography to detect muscle damage in sports. *Physiological Measurement* **45**(9), 095014 (2024)
- Sanchis-Sánchez, E., Vergara-Hernández, C., Cibrián, R.M., Salvador, R., Sanchis, E., Codoñer-Franch, P.: Infrared thermal imaging in the diagnosis of musculoskeletal injuries: a systematic review and meta-analysis. *American Journal of Roentgenology* **203**(4), 875–882 (2014)
- Lacerda, A.P.D., Andrade, P.R.d., Kamonseki, D.H., Parizotto, N.A., Silva, A.S.A., Medeiros, L.B., Almeida Ferreira, J.J.d.: Accuracy of infrared thermography in detecting tendinopathy: a systematic review with meta-analysis. *Physical Therapy in Sport* **58**, 117–125 (2022)
- Bargiel, P., Czapla, N., Prowans, P., Kotrych, D., Ziętek, P., Lusina, D., Łęgosz, P., Petriczko, J.: Thermography in the diagnosis of carpal tunnel syndrome. *Open Medicine* **16**(1), 175–182 (2021)
- Manchado, F.d.B., Gobatto, C.A., Contarteze, R.V.L., Papoti, M., Mello, M.A.R.d.: Máxima fase estável de lactato é ergômetro-dependente em modelo experimental utilizando ratos. *Revista Brasileira de Medicina do Esporte* **12**(5), 259–262 (2006)
- Little, M.A., Varoquaux, G., Saeb, S., Lonini, L., Jayaraman, A., Mohr, D.C., Kording, K.P.: Using and understanding cross-validation strategies: perspectives on Saeb et al. *GigaScience* **6**(5), 1–6 (2017) <https://doi.org/10.1093/gigascience/gix020>
- Castro, C.L.d., Braga, A.P.: Aprendizado supervisionado com conjuntos de dados desbalanceados. *Sba: Controle & Automação* **22**(5), 441–466 (2011)
- Demšar, J.: Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research* **7**, 1–30 (2006)
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., Fei-Fei, L.: ImageNet: a large-scale hierarchical image database. In: *IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255 (2009)
- Ioffe, S., Szegedy, C.: Batch normalization: accelerating deep network training by

- reducing internal covariate shift. In: International Conference on Machine Learning, pp. 448–456 (2015)
- Kingma, D.P., Ba, J.: Adam: a method for stochastic optimization. In: International Conference on Learning Representations (2015)
- He, K., Zhang, X., Ren, S., Sun, J.: Deep residual learning for image recognition. In: IEEE Conference on Computer Vision and Pattern Recognition, pp. 770–778 (2016)
- Weiss, K., Khoshgoftaar, T.M., Wang, D.: A survey of transfer learning. *Journal of Big Data* **3**(1), 1–40 (2016)
- Breiman, L.: Random forests. *Machine Learning* **45**(1), 5–32 (2001)
- Brodersen, K.H., Ong, C.S., Stephan, K.E., Buhmann, J.M.: The balanced accuracy and its posterior distribution. In: 20th International Conference on Pattern Recognition, pp. 3121–3124 (2010)
- Davis, J., Goadrich, M.: The relationship between precision-recall and ROC curves. In: Proceedings of the 23rd International Conference on Machine Learning, pp. 233–240 (2006)
- Efron, B., Tibshirani, R.J.: *An Introduction to the Bootstrap*. Chapman & Hall, New York (1993)
- Wilcoxon, F.: Individual comparisons by ranking methods. *Biometrics Bulletin* **1**(6), 80–83 (1945)
- Winter, E.: The Shapley value. In: *Handbook of Game Theory with Economic Applications* vol. 3, pp. 2025–2054 (2002)
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., *et al.*: PyTorch: an imperative style, high-performance deep learning library. In: *Advances in Neural Information Processing Systems* **32**, pp. 8024–8035 (2019)
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., *et al.*: Scikit-learn: machine learning in Python. *Journal of Machine Learning Research* **12**, 2825–2830 (2011)